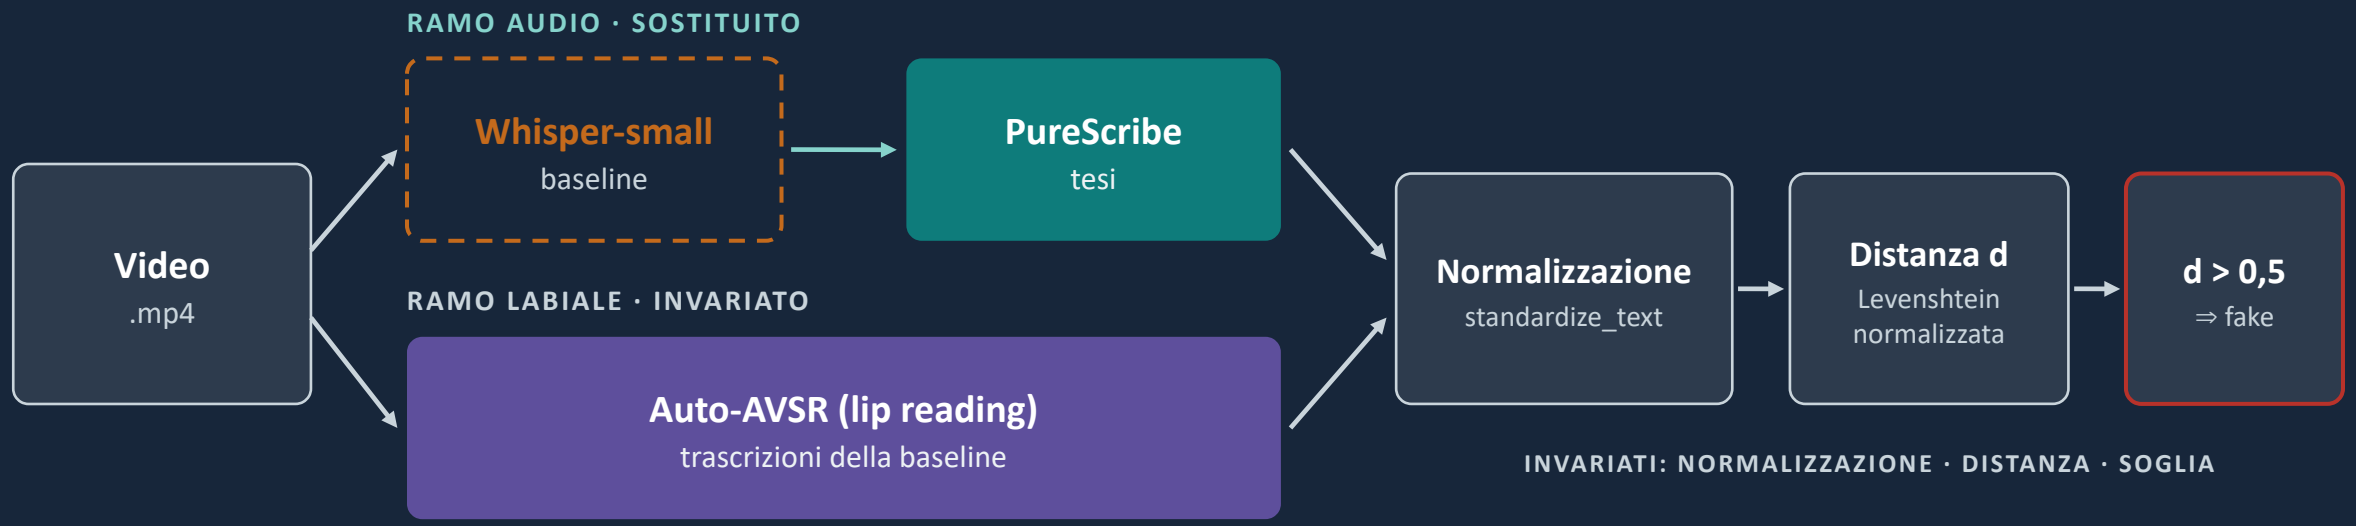
Whisper → PureScribe in “Lost in Translation”

Lip-sync deepfake: disallineamento tra trascrizione dell’audio e del labiale (Bohacek & Farid, CVPRW 2024)



DOMANDA SPERIMENTALE

A parità di video, trascrizioni labiali, normalizzazione, distanza, soglia e protocollo, come cambiano le prestazioni di rilevamento se Whisper è sostituito da PureScribe?

Preparazione offline: da Common Voice al modello .psm

COSTRUZIONE DEL CORPUS · commonvoice_purescribe.py extract → purescribe.cli train

1 **Common Voice dev**
MP3 + trascrizioni ufficiali

→

2 **Whisper base**
solo audio → timestamp per parola; nessun testo, prompt o align()

→

3 **Match esatto**
monotono, casefold; un token Whisper mai riusato

→

4 **Clip WAV**
etichetta = parola ufficiale; 10–20 clip per parola

→

5 **Addestramento**
purescribe.cli train → modello .psm

Dentro PureScribe riconoscitore classico · nessuna rete neurale · vocabolario chiuso V = parole del corpus

MFCC
finestre 25 ms, passo 10 ms; 26 filtri mel; 13 coeff. + Δ + ΔΔ = 39 dim; CMVN globale

→

HMM-GMM per parola
left-to-right, 3–24 stati; 2 gaussiane diagonali per stato; addestramento Viterbi (segmental k-means)



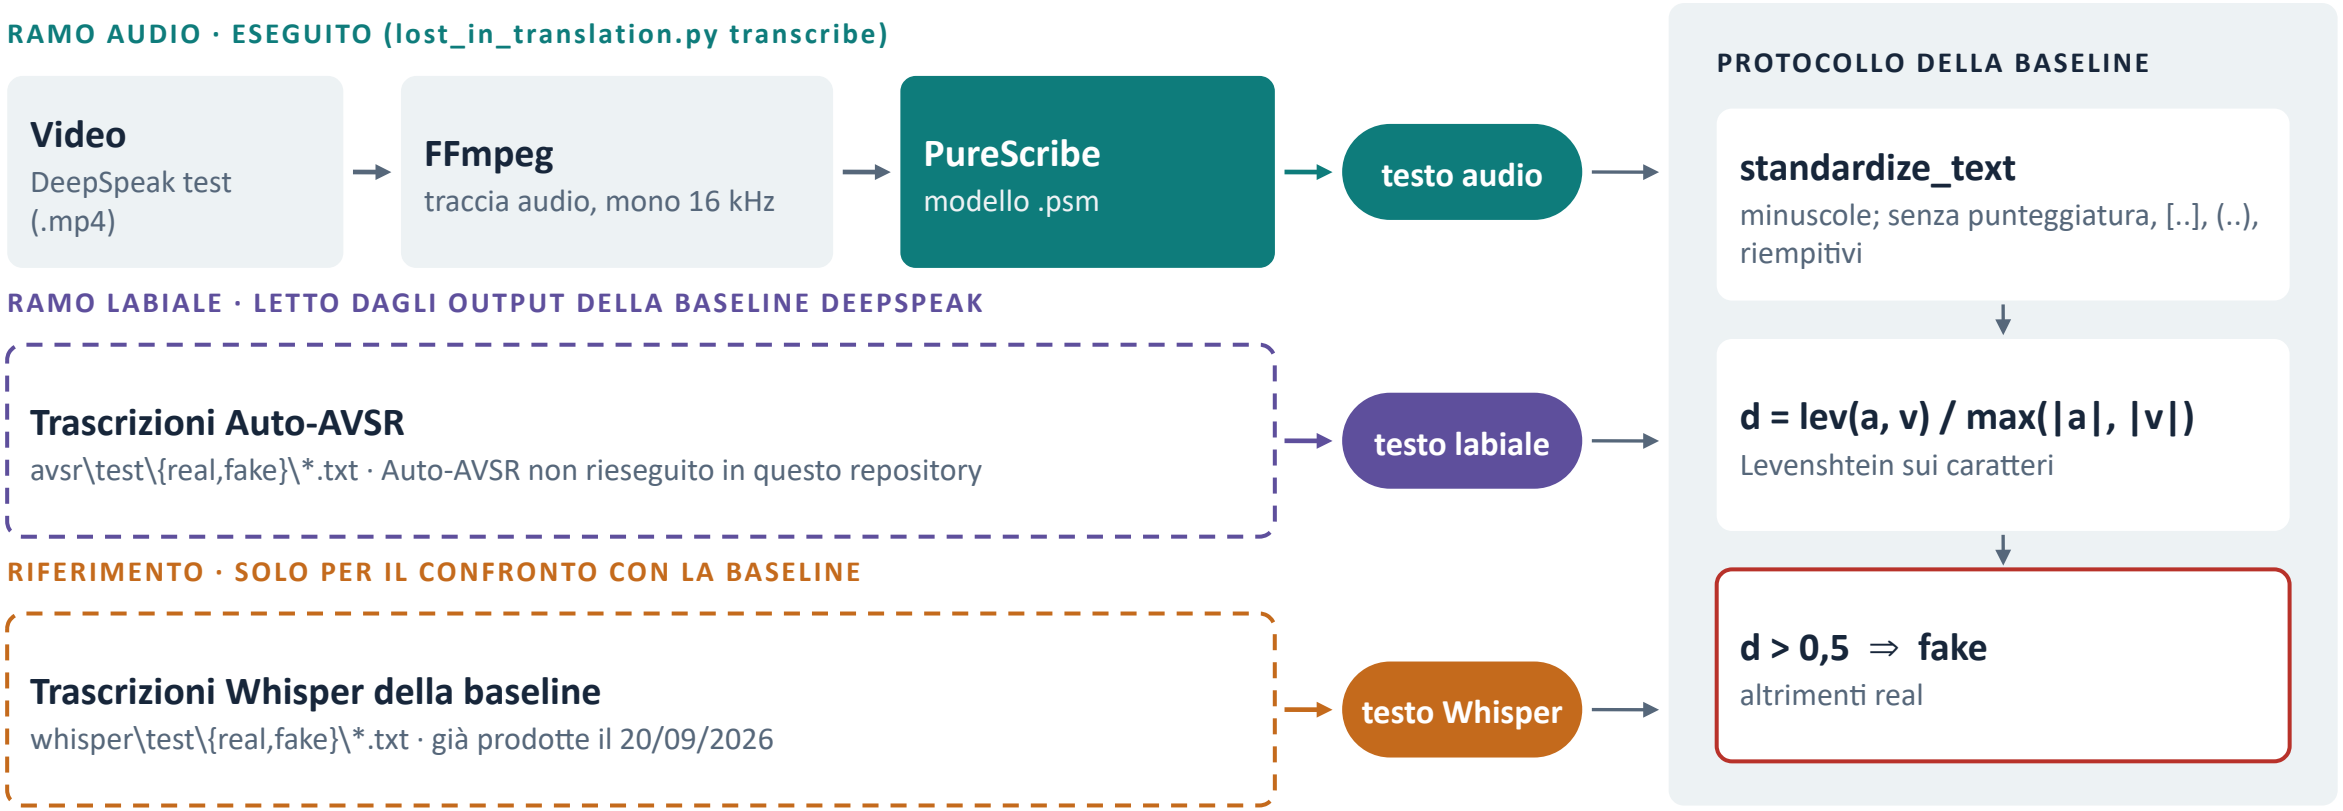
→

Decodifica Viterbi
token passing su un loop di modelli di parola + silenzio; beam search

→

Testo
solo parole di V

Pipeline finale: PureScribe trascrive l'audio dei video



Whisper non viene eseguito nella pipeline finale: le sue trascrizioni servono solo a ricalcolare le metriche della baseline sugli stessi video.

Riproduzione: quattro comandi in una nuova directory

```
# PowerShell, dalla root del repository
# prerequisiti: .venv (numpy, scipy, openai-whisper), ffmpeg nel PATH,
#               Whisper base in cache, trascrizioni della baseline

$RUN = "C:\Users\cofon\Desktop\thesis_lit_purescribe_20261016_01"
$PY  = ".\.venv\Scripts\python.exe"
$BT  = "C:\Users\cofon\DeepSpeak\transcriptions"

# 2 · extract
& $PY commonvoice_purescribe.py extract --data-root D:\CommonVoice `
    --audio-dir D:\CommonVoice\dev `
    --transcription-file D:\CommonVoice\cv_path_transcription.txt `
    --output $RUN\corpus

# 3 · train
& $PY -m purescribe.cli train $RUN\corpus -o $RUN\purescribe.psm

# 5 · transcribe
& $PY lost_in_translation.py transcribe --model $RUN\purescribe.psm `
    --baseline-transcripts $BT --subset test `
    --videos-dir D:\DeepSpeak\test --output $RUN\deepfake_purescribe.tsv

# 6 · compare
& $PY lost_in_translation.py compare --baseline-transcripts $BT `
    --subset test --purescribe $RUN\deepfake_purescribe.tsv `
    --threshold 0.5 --output $RUN\deepfake_comparison.json
```

ARTEFATTI IN $RUN

2 **corpus**
<parola>*.wav · clips.jsonl · extraction.json

3 **purescribe.psm**
modello HMM-GMM

5 **deepfake_purescribe.tsv**
una riga per video: stato, testo, SHA-256

6 **deepfake_comparison.json**
metriche Whisper vs PureScribe, per video

$RUN deve essere nuova

Non sovrascrivere D:\CommonVoice, corpus\, words.psm, temp_iso.wav, Desktop\words_cv né esperimenti precedenti.

Limiti da tenere presenti nell’interpretazione

V

Vocabolario chiuso

PureScribe emette solo parole addestrate: le parole fuori vocabolario alzano la distanza dal labiale anche nei video autentici.

L

Ramo labiale già disponibile

Le trascrizioni Auto-AVSR sono quelle della baseline DeepSpeak (124 video); 120 video sono ancora su disco.

≠

Dominio acustico diverso

Training: parole isolate tagliate da frasi lette (MP3 Common Voice). Test: parlato continuo dei video DeepSpeak.

%

Classi sbilanciate

100 fake e 20 real: dichiarare sempre “fake” dà accuracy 83,3% e F1 90,9%. Leggere TN e FP.

Inoltre: confini delle parole non verificati all’ascolto · soglia 0,5 non ritarata · baseline locale diversa dal paper (Whisper-small multilingue).